

헤이즐넛 이미지를 활용한 이상 탐지 및 결함 위치 시각화



목차

01

프로젝트 개요

02

프로젝트 팀 구성 및 역할

03

프로젝트 수행 절차 및 방법

04

프로젝트 수행 경과

- 색상 히스토그램
- HOG 기법

- LBP 기법
- HOG + LBP 기법

05

자체 평가 의견

선택한 카테고리와의 선택 이유

Bottle



형태 및 윤곽선 중심


hazelnut



질감 및 표면 미세 패턴 중심

수업시간에 배우지 않은 데이터셋의 특성으로 진행

프로젝트 팀 구성 및 역할



파라미터 통일


```
n_estimators=500, # 트리 수를 늘려 더 세밀한 결정 경계 구축
contamination='auto', # percentile 임계값을 별도로 사용하므로
                        기본값('auto') 설정
max_features=1.0, # 모든 격자 특징을 반영하여
                  국소적 결함 정보 손실 방지
max_samples=0.8, # 80% 샘플링으로 트리 간 다양성 및 일반화 성
                  능 확보
random_state=42 # 실행 시마다 동일한 결과를 얻기 위해 난수 초기
                  값 고정
```

프로젝트 프로세스

	Day1 3/20(금)	Day2 3/21(토)	Day3 3/22(일)	Day4 3/23(월)
대주제 탐색 및 선정	대주제 탐색 및 선정			
소주제 탐색 및 선정		소주제 탐색 및 선정		
데이터 분석		데이터 분석		
발표 자료 작성			발표 자료 작성	

프로젝트 총 수행 기간 : 4일

프로젝트 사용 툴



데이터 구조

Crack



Cut



Good



Print



Hole



데이터: MVTec AD hazelnut (train 391장 / test 110장: 정상 40, 이상 70)

프로젝트 워크플로우

1 단계 데이터 이해

- 선택한 카테고리 구조 확인
- 정상 이미지와 이상 이미지 차이 관찰
- 결함 종류 정리

2 단계 데이터 준비

- train/good 를 학습용으로 사용
- test/good 와 test/이상유형을 평가용으로 사용

3 단계 특징 추출

- 색상 특징 ,
질감 (HOG, LBP)특징

4 단계 모델 학습

- 기본 : Isolation Forest
- 확장 가능 : One-Class SVM, LOF 모델 비교

5 단계 판별 기준 설정

- 학습 이미지 점수 기반으로 threshold 설정
- threshold 변화에 따른 결과 비교

6 단계 이상 위치 시각화

- 정상 참조 이미지와 테스트 이미지 차이 계산
- thresholding, morphology, contour 활용 이상 부위 박스 표시

7 단계 결과 분석

- 잘 검출되는 이상 유형
- 잘 안 검출되는 이상 유형
- 오탐 / 미탐 원인 분석
- 데이터 특성과 알고리즘 한계 설명

색상 히스토그램



장 윤 진

색상 히스토그램으로 이상을 탐지할 수 있을까?

이미지의 통계량을 구하는 가장 계산량이 적고 빠른 기법 중 하나



색상 특징 추출 파이프라인

[Step 1] 원본 이미지 입력

해상도와 크기가 다양한 불균일한 헤이즐넛 이미지 로드

[Step 2] 공간 사이즈 조절

연산 효율 및 입력 데이터 일관성을 위해 128x128 픽셀 크기로 통일

[Step 3] 색상 공간 변환

Open CV 사용하여 RGB 이미지를 조명에 강한 H(색상)S(명도)V(채도) 공간으로 변환

[Step 4] 색상 히스토그램 추출

HSV 각 채널을 8구간으로 분할하여 총 512개(8x8x8)의 색상 빈도 집계

[Step 5] 픽셀값 정규화

단순 픽셀 수를 '전체 대비 비율(확률 분포)'로 압축

→ 픽셀 수에 영향 받지 않도록 함



[Step 6] 특징 벡터화

3차원 공간 정보가 제거된 1차원 배열 (512차원) 생성

→ Isolation Forest 모델 학습

색상


정상 / 이상 판별 & 성능 개선 시도



색상

결함별 평균 점수

Average Anomaly Score by Defect Type (Color Histogram)




형태나 구조 변화만
있는 결함 탐지 X

BUT

색 분포가 크게 변
하는 결함에는 민감
하게 반응

색상


실패 사례와 원인 분석 - Cut(균 힘)



흠집을 세로 줄무늬로 오인
-> 정상보다 높은 점수 결과

색상

실패 사례와 원인 분석 - Hole(구멍)



구멍으로 인한 그림자
픽셀 면적이 좁음

색상

실패 사례와 원인 분석 - Crack(균열)

crack
GT: 이상 / Pred: 정상
Score: 0.0135



good
GT: 정상 / Pred: 정상
Score: 0.1722



crack
GT: 이상 / Pred: 정상
Score: 0.0531




good
GT: 정상 / Pred: 정상
Score: 0.1470



겉껍질과 속살의
색상이 유사함

색상

실패 사례와 원인 분석 - PRINT(인쇄)



색상에 가장 민감함
-> 유의미한 결과

색상

중간 결론

색상 히스토그램의 한계

: 화학적 오염(Print)에는 유의미하게 반응하나,
물리적 훼손(Cut, Crack, Hole) 탐지 불가

=> 단순 색상 비율이 아닌 **윤곽선(Edge)**과 **질감(Texture)** 학습 필요


=> 헤이즐넛 이상 탐지에 **HOG, LBP** 특징 추출 방식을 적용해보자!

HOG 기법




이 유 경

HOG(Histogram of Oriented Gradients)?




- 이미지의 형태와 구조를 숫자로 표현하는 방법
- 이미지를 작은 구역으로 나누고, 각 구역에서 픽셀 밝기가 어느 방향으로 변하는지를 히스토그램으로 정리한 특징 벡터
- 균열이 생기면 그 경계선 부분에서 밝기 변화가 뚜렷하게 나타나는데, HOG는 이런 방향 정보를 수치화 함
- 형태 변화가 뚜렷한 결함에는 강하지만 색상 변화나 회전에는 취약

threshold 설정 방법




- 정상 학습 이미지의 이상 점수 계산 후 percentile 0~100 구간을 5 단위로 순회하며 precision/recall/F1 score 변화 측정
- F1 score 기준 최고점인 percentile=65를 최종 threshold로 선택 (threshold=0.0621)

threshold 설정 방법




- 정상 학습 데이터 점수의 하위 65%에 해당하는 값을 기준으로 설정하고 테스트 점수가 이 값보다 낮으면 이상으로 판별
→ HOG 특징이 헤이즐넛의 정상/이상을 충분히 구분하지 못하고 있음

정상/이상 판별 결과



- 이상 70개 중 65개 검출, 정상 40개 중 25개를 이상으로 오탐
- threshold를 높게 설정할수록 (65%) 이상 검출률은 올라가지만 정상 오탐도 함께 증가


정상/이상 판별 결과



	Precision	Recall	F1-score
정상 (normal)	0.75	0.38	0.50
이상 (anomaly)	0.72	0.93 ★	0.81

- anomaly 클래스 기준으로는 recall이 0.93으로 높음
- normal 클래스 기준 recall=0.38
→ threshold 상향의 부작용

잘 된 사례 / 실패 사례



- 잘 된 사례

- crack: 표면에 선명한 경계선이 생겨 HOG가 기울기 방향 변화를 명확히 포착

- 실패 사례

- good(정탐률 0.375): 헤이즐넛의 자연적인 회전 변동성으로 인해 정상/이상 점수 분포가 크게 겹침

성능 개선 시도 내용

개선 방법	결과	비고
StandardScaler 정규화 추가	성능 향상	랜덤 분기에 스케일 영향 제거
Percentile 5% → 65%	anomaly recall 0.14 → 0.93	F1 기준 최적값 탐색
contamination auto 설정	안정적 학습	데이터 비율 자동 추정

HOG 결론

- **anomaly recall 0.93**, 특히 경계선이 뚜렷한 crack, cut, print에서 높은 검출률을 보임
- **threshold를 높게** 설정할수록 recall이 올라가지만 **정상 오탐도 함께 증가**하는 trade-off 때문에 정상 오탐률이 높았음
- HOG 특징으로는 정상과 이상이 점수상으로 명확히 분리되지 않고 **분포가 중첩**됨

→ 경계성 결함을 놓치지 않는 **1차 스크리닝 용도로는 유효**했으나 정상 이미지의 회전·자세 변화로 인해 정상/이상 점수 분포가 중첩되어 **단독 판별 모델로 사용하기에는 한계**

LBP 기법




박영현


사용한 특징 추출 방식

LBP (Local Binary Pattern): 픽셀 밝기 비교로 이미지 질감을 숫자로 변환하는 기법

인코딩 원리




원본 픽셀 밝기값



이진화

- 이웃 픽셀 > 기준값 → 1
- 이웃 픽셀 < 기준값 → 0




전환 횟수 계산: 6회

bin	코드	전환 횟수	의미
0	00000000	0	완전 어두운 영역 (평탄)
1	00000001	1	특정 방향 엣지
2	00000011	1	
3	00000111	1	
4	00001111	1	
5	00011111	1	
6	00111111	1	
7	01111111	1	
8	11111111	1	
9	10100100	2회 이상	non-uniform (복잡한 패턴)

히스토그램으로
집계

threshold 설정 방법

Threshold Percentile 실험 결과




Anomaly F1과

Normal Recall의 균형을 기준으로 선택

정상 / 이상 판별 결과

수치 결과

지표	값
Anomaly F1	0.695
Anomaly Recall	0.70 (70장 중 49장 탐지)
Anomaly Precision	0.69
Normal Recall	0.45



FN을 줄이는 대신 FP가 증가하는 트레이드오프

잘된 사례 / 실패 사례

2장 모두 탐지 성공
껍질이 크게 갈라진 명확한 결함
→ LBP가 경계 패턴 변화를 잘 포착



1장 성공, 1장 실패

1장 성공, 1장 실패



2장 모두 탐지 성공



정상 이미지 3장이 이상으로 오탐

→ threshold를 45%ile로 낮게 설정해 이상 탐지 민감도를 높인 결과
FN을 줄이는 대신 FP 증가는 의도된 트레이드오프

성능 개선 시도

	초기	Grid 4×4 추가	256×256 변경	최종 (45%ile)
	단일 LBP, 5%ile	전역 → 4×4	128 → 256	threshold 조정
Anomaly Recall	0.21	0.47	0.79	0.70
Normal Recall	0.88	0.62	0.23	0.45
FN (이상을 정상으로 잘못 예측)	55	37	15	21

LBP 결론

LBP + Isolation Forest의 구조적 한계

- LBP는 밝기 대소만 비교 → 색상 변화(오염 등) 탐지 어려움
- 두 한계가 겹치는 결함(작은 cut, 작은 hole)에서 FN 발생

제약 조건 내 최선

- LBP, Isolation Forest만 사용이라는 제약 안에서 Grid 4×4, 멀티스케일, threshold 실험으로 초기 대비 FN 55 → 21 감소

HOG + LBP 기법



이 현 아

특징추출

HOG

윤곽선

LBP


패치



HOG + 윤곽선 + 패치 기법

특징추출

- 윤곽선: Crack은 잘 탐지하지만, 나머지 불량 유형은 잘 탐지하지 못함




HOG + 윤곽선 방식 → 전체 이미지의 형태를 확인하는 기법이지만
헤이즐넛 결함은 국소적인 부분에 있어 전체 특징으로는 구분이 어려움

IsolationForest 판별 결과

최적 threshold	anomaly f1	normal recall
35	0.661	0.62

*최적 threshold 탐색 방법: 5단위로 값을 순회하며 anomaly f1, normal recall이 균형을 이루는 threshold 선택

어떤 특징추출 과정을 거치든,
anomaly f1, normal recall이 균형을 이루려면
즉, 불량도 잘 잡고 정상도 잘 판별하려면
IsolationForest 모델은 한계가 있음을 확인



모델 추가 학습

정상의 경계를 학습하는 One-Class SVM

주변 이웃과 비교하는 LOF



두 모델을 추가로 학습


ROC 커브 비교

- One-class SVM

최적 threshold	anomaly f1	normal recall
25	0.711	0.80


- LOF

최적 threshold	anomaly f1	normal recall
30	0.866	0.85




Isolation Forest vs LOF 판별 결과

Isolation Forest





LOF



* 이미지 위 글자: 초록색 - 정답, 빨간색 - 오답

LOF


- 정상도 잘 잡고 불량도 잘 판별 → LOF 모델이 헤이즐넛 데이터에 가장 적합




* anomaly f1: 0.866, normal recall: 0.85

이상위치 판별 한계

- 이미지의 방향이 제각각이라 정상 부위도 박스로 잡히는 노이즈 발생
 - 회전 또한 헤이즐넛 형태에 명확한 방향 기준이 없어서 어려움
- ⇒ **정확한 이상 위치 판별을 위해서는 딥러닝 필수**



Print처럼 밝기 변화가 뚜렷한 경우
실제 결함 위치를 잘 탐지



Cut처럼 미세한 결함은 방향 차이로 인한
노이즈에 묻혀서 정확한 위치 탐지가 어려움

최종결론



헤이즐넛 데이터 특성: 헤이즐넛의 방향이 이미지마다 제각각이고, 결함 크기의 스펙트럼이 넓음



특징 추출 (세 가지 특징을 추출하여 결합)

- 경계선 방향을 잡는 HOG
- 내부 구멍과 형태 변형을 탐지하는 윤곽선
- 국소적 밝기 변화를 분석하는 패치



모델

주변 이웃과 비교하는 **LOF 모델**이
다양한 패턴을 가진
헤이즐넛 데이터에 가장 적합

자체 평가 의견

01

완성도 평가

9점 / 10점

02

잘한점과 아쉬운점

- 잘한점
 - 수업 시간에 배운 예제를 활용하여 미니 프로젝트를 진행함
 - 각자의 기법을 사용하여 결과를 도출한 후 모델의 정확성을 높이기 위해 수정 보완함
- 아쉬운점
 - 이미지 전처리 기법을 각자 다르게 사용했는데 기본적인 방식들에서는 결과 수치가 낮게 나온 것이 아쉬웠음

03


개선점

- 이번 프로젝트에서는 Isolation Forest 모델을 주로 사용했는데 각 이미지 전처리 기법에 다른 머신러닝 모델들을 접목하면 성능을 더 높일 수 있을 것으로 기대됨

04

느낀점

- 딥러닝을 배우기 전에 이미지 전처리 하는 방법을 배울 수 있어서 좋았음
- 머신러닝으로는 이미지를 분류하는 것에 한계가 있다는 것을 알았음



감사합니다

